

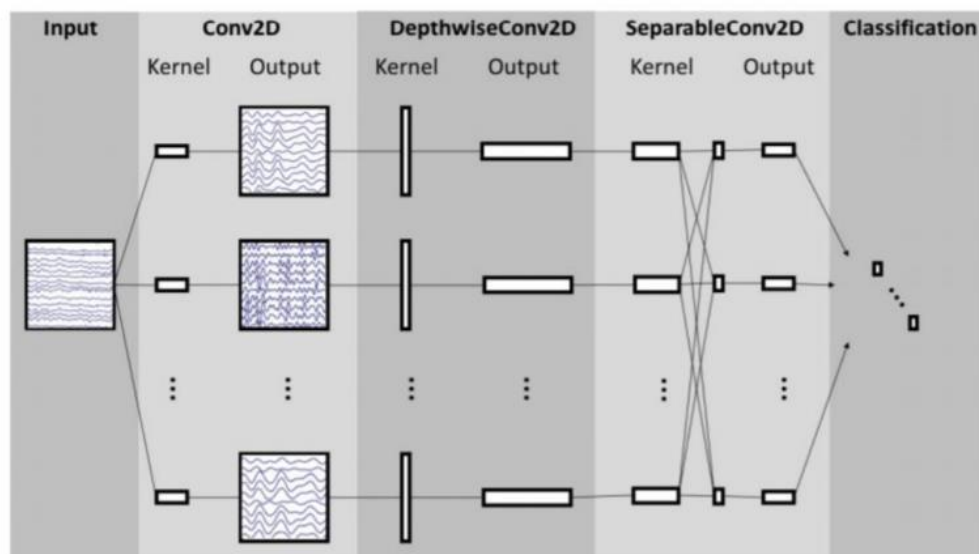
Introduction

本次作業會使用 EEGNet 深度學習模型來進行 EEG 資料的二元分類，並且我希望透過調整不同參數以及 activation model 來測試出能達到最佳表現的組合。

Methods

2.1 EEGNet 模型建立

EEGNet 是一種精巧的 CNN 模型，可用於進行 EEG 相關訊號的分類以及重要特徵擷取。EEGNet 透過 depthwise convolution 及 separable convolution 兩種捲積層的方式來進行分類。與傳統的 convolution 方式不同，在 depthwise convolution 中每個 kernel 都會產出一個對應的 output，而在 separable convolution 中則是結合了 depthwise convolution 與傳統 pointwise convolution 的做法，每個 kernel 先各自進行運算後再將運算結果結合進行輸出。EEGNet 的模型示意圖如下：



2.2 不同的 Activation function

a. ReLU

Relu 的函式定義如下：

$$f(x) = \max(x, 0)$$

即當輸入值為大於 0 時，此函式會輸出輸入值本身，當輸入值小於等於 0 時，則會輸出 0。

b. Leaky ReLU

Leaky ReLU 函式定義如下：

$$f(x) = \max(\alpha x, x)$$

為了修正在 ReLU 中可能遇到的 dying ReLU 問題，Leaky ReLU 便被提出。此處的 α 是一常數且通常被設成極小的正值如 0.01。Leaky ReLU 和 ReLU 的主要區別即在於 Leaky ReLU 透過 α 來調整當輸入值為負數時的函式輸出，而非全部輸出為 0。

c. ELU

ELU 的函式定義如下：

$$ELU(x) = \begin{cases} x, & \text{if } x > 0 \\ \alpha * (exp(x) - 1), & \text{if } x \leq 0 \end{cases}$$

ELU 的主要優勢包含：


1. 一直到此函式的輸出值為 $-\alpha$ 前，ELU 的函式的輸出皆較為平滑。
2. 此函式同樣可以產出負數值

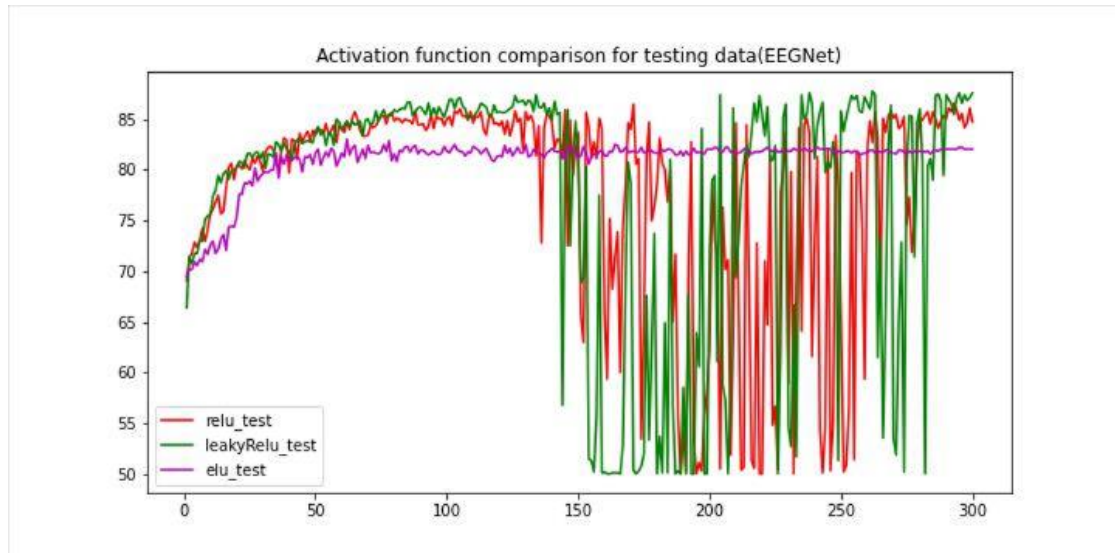
然而，Relu 函式在輸入值為正數時，有可能因為輸入值過大而造成輸出值變成 $[0, \infty]$ 的情形。

Results

a. 不同 activation function 結果比較

```
100%| 300/300 [03:14<00:00, 1.54it/s]
100%| 300/300 [02:38<00:00, 1.89it/s]
100%| 300/300 [02:46<00:00, 1.80it/s]
Test acc of ReLu: 86.57407407407408, Test acc of ELu: 83.05555555555556, Test acc of LeakyReLu: 87.77777777777777
```





b. 不同 α 值的 ELU 結果比較

	Alpha = 0.4	Alpha = 0.7	Alpha = 1.0
Accuracy	83.52	83.43	83.06

c. 不同 Dropout rate 的結果比較

	Dropout = 0.25	Dropout = 0.5	Dropout = 0.75
Accuracy	86.57	88.98	87.41

Discussion

本次作業中我一共做了三種不同比較，使用的皆是 EEGNet 的模型，分別是：

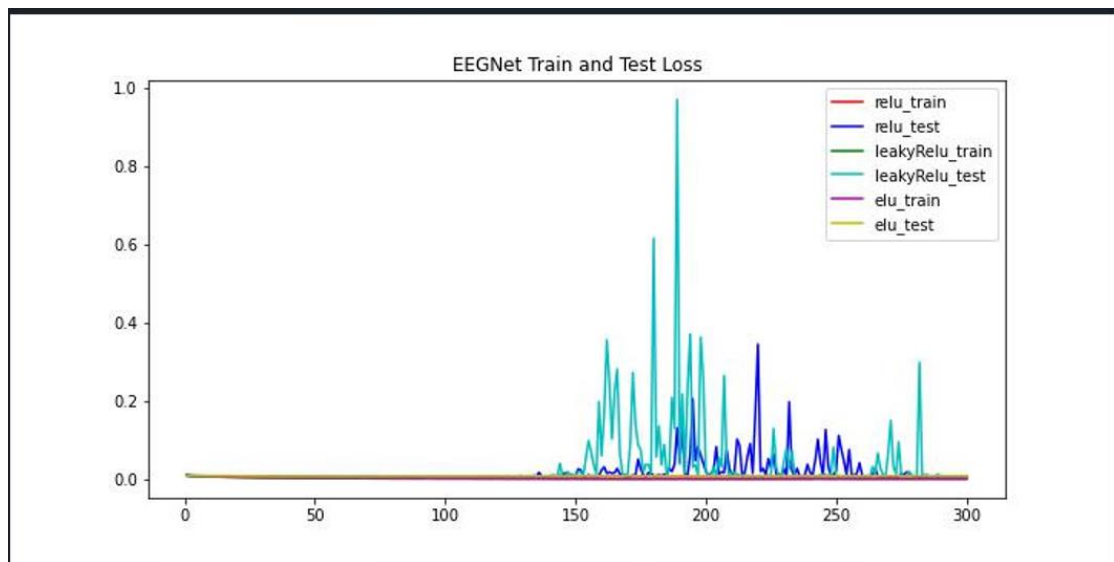
1. 比較不同 Activation function 對分類結果的影響
2. 比較不同 α 值對 ELU model 的分類結果影響
3. 比較不同 dropout rate 對 ReLU model 的分類結果影響

以下將分此三部分進行討論

a. 不同 Activation function 的比較

從帳面數據來看，使用 Leaky ReLU 的模型有最高的平均準確率(87.78%)，然而若從 loss function 的角度來看(參考下圖)，可以發現 ReLU 及 Leaky

ReLU 兩個 Activation function 在 test data 的表現是有問題的，相較之下 ELU activation function 不管是使用 training data 還是 test data 都維持 converge 的情形，儘管其準確率表現並非最佳，但在 test data 上的表現較優。



b. 不同 alpha 值對 ELU 結果的影響

從表格中可以發現當 Alpha 值越小時，ELU 模型的表現結果有略微上升的趨勢 (從 83.06% 上升至 83.52%)

c. 不同 dropout rate 對 ReLU 結果的影響

從表格中可以發現，當 dropout rate 設定在 0.5 時，ReLU 模型有最佳的表現 (88.98%)，但當 dropout rate 訂得太高時表現反而又呈現下滑。